

Validez del Teorema de Cochran en la Estimación de la Varianza: Un Análisis Comparativo entre Distribuciones Normal, Exponencial y t de Student

Lukas Wolff Casanova

Facultad de Ingeniería y Ciencias Aplicadas, Universidad de los Andes, Santiago de Chile

e-mail: lwolff@miuandes.cl

GitHub: [Repositorio](#)

ABSTRACT

This work analyzes the validity of Cochran's Theorem for variance estimation across three probability distributions: Normal, Exponential, and Student's t. Using samples of size $n = 100$ and 1000 Monte Carlo repetitions, 95 % confidence intervals for the population variance were constructed via the χ^2 statistic and their empirical coverage was evaluated. Results show that the Normal distribution achieves exact nominal coverage (95,5 %), consistent with Cochran's Theorem. The Exponential distribution (95,6 %) confirms asymptotic validity through the Central Limit Theorem. However, the Student's t distribution yields only 86,2 % coverage, revealing that heavy tails prevent convergence even at $n = 100$. These findings highlight that the applicability of χ^2 -based inference depends critically on the tail behavior of the underlying distribution.

Key words: Cochran's Theorem, confidence intervals, variance estimation, Student's t distribution.

1. Introducción

Una distribución de probabilidad es un modelo matemático que describe cómo se reparte la incertidumbre asociada a una variable aleatoria. Estas distribuciones son fundamentales en estadística, ya que permiten modelar y analizar datos, realizar inferencias y tomar decisiones informadas. En este informe, se explorarán diferentes distribuciones de probabilidad, sus propiedades y aplicaciones en el análisis de datos Fisher [1922].

En términos aplicados, elegir una distribución equivale a postular una estructura para los datos: por ejemplo, la distribución Normal suele usarse cuando predominan efectos aditivos y simétricos; la Exponencial es natural para tiempos de espera y procesos de ocurrencia aleatoria; y la t de Student aparece de manera fundamental en inferencia sobre medias cuando la varianza poblacional es desconocida, especialmente en muestras pequeñas. Estas distribuciones no solo describen datos, sino que también determinan la forma de los estadísticos muestrales y, por tanto, la validez de intervalos de confianza, pruebas de hipótesis y métodos de estimación.

El presente trabajo tiene como objetivo analizar y comparar diferentes distribuciones de probabilidad, evaluan-

do empíricamente la validez del Teorema de Cochran para la estimación de la varianza poblacional mediante intervalos de confianza basados en el estadístico χ^2 . En específico, se compararán las distribuciones Normal, Exponencial a tasa $\lambda = 0,5$ y t de Student con $\nu = 5$ grados de libertad. Además, se realizará un análisis descriptivo de la distribución t de Student, explicando su comportamiento y aplicaciones en el análisis de datos. Finalmente, se discutirán las implicancias de los resultados obtenidos y se presentarán conclusiones sobre la importancia de elegir adecuadamente la distribución de probabilidad en el análisis estadístico.

2. Metodología

2.1. Teorema de Cochran

El Teorema de Cochran Cochran [1934] establece una propiedad fundamental de la distribución Normal: si $X_1, X_2, \dots, X_n \stackrel{\text{iid}}{\sim} \mathcal{N}(\mu, \sigma^2)$, entonces la varianza muestral S_n^2 y la media muestral $\bar{X}$ son estadísticos independientes, y además:

$$\frac{(n-1)S_n^2}{\sigma^2} \sim \chi_{n-1}^2 \quad (1)$$

Este resultado es *exacto* bajo normalidad, y constituye la base teórica para la construcción de intervalos de confianza para la varianza poblacional σ^2 . En particular, un intervalo al 95 % de confianza se obtiene a partir de los cuantiles $\chi_{\alpha/2, n-1}^2$ y $\chi_{1-\alpha/2, n-1}^2$:

$$\left[\frac{(n-1)S_n^2}{\chi_{1-\alpha/2, n-1}^2}, \frac{(n-1)S_n^2}{\chi_{\alpha/2, n-1}^2} \right] \quad (2)$$

La condición crítica del teorema es la normalidad de los datos. Si los X_i no provienen de una distribución Normal, la distribución exacta de $(n-1)S_n^2/\sigma^2$ deja de ser χ_{n-1}^2 , y el intervalo de confianza construido bajo ese supuesto puede resultar inválido. No obstante, el Teorema Central del Límite garantiza que, para muestras suficientemente grandes, el estadístico converge en distribución a χ_{n-1}^2 incluso para distribuciones no normales, siempre que estas posean momentos finitos de orden suficiente y colas no demasiado pesadas.

2.2. Distribuciones de Probabilidad

Las distribuciones de probabilidad permiten modelar la incertidumbre asociada a variables aleatorias, describiendo cómo se distribuyen sus valores posibles. En este trabajo se consideran distintas distribuciones con el objetivo de analizar sus propiedades y su impacto en la inferencia estadística, particularmente en la estimación de la varianza poblacional.

2.2.1. Distribución Normal

Completamente definida por μ y σ^2 , su densidad es:

$$f(x) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right) \quad (3)$$

Es la única distribución para la cual el Teorema de Cochran aplica de forma exacta.

2.2.2. Distribución χ^2

Surge como suma de cuadrados de variables normales estándar independientes. Bajo normalidad, el estadístico $(n-1)S^2/\sigma^2 \sim \chi_{n-1}^2$ permite construir intervalos de confianza exactos para σ^2 , cuya validez fuera de la normalidad es lo que se evalúa en este trabajo.

2.2.3. Distribución Exponencial

Modela tiempos de espera con tasa $\lambda > 0$, media $1/\lambda$ y varianza $1/\lambda^2$. No cumple el Teorema de Cochran, pero su curtosis constante igual a 6 permite que la aproximación χ^2 sea asintóticamente válida para n suficientemente grande.

2.2.4. Distribución t de Student

La distribución t de Student Student [1908] surge al estimar la media de una población normal cuando la varianza poblacional es desconocida. Definida por sus grados de libertad $\nu > 0$, su densidad es:

$$f(x) = \frac{\Gamma(\frac{\nu+1}{2})}{\sqrt{\nu\pi}\Gamma(\frac{\nu}{2})} \left(1 + \frac{x^2}{\nu}\right)^{-\frac{\nu+1}{2}} \quad (4)$$

Su varianza, definida para $\nu > 2$, se calcula como:

$$\text{Var}(X) = \frac{\nu}{\nu-2} \quad (5)$$

lo que refleja que a mayor ν , menor dispersión, convergiendo a 1 cuando $\nu \rightarrow \infty$, momento en que la distribución se aproxima a la Normal estándar. Para $\nu > 4$, la curtosis es $\kappa = 6/(\nu-4)$, que diverge cuando $\nu \rightarrow 4^+$, evidenciando el peso creciente de las colas para valores pequeños de ν .

En el mundo real, la distribución t de Student tiene aplicaciones en cualquier contexto donde se trabaje con muestras pequeñas y varianza desconocida: ensayos clínicos, control de calidad industrial y, de particular relevancia en ingeniería civil, en técnicas experimentales de análisis de fluidos como *Particle Image Velocimetry* (PIV) y *Particle Tracking Velocimetry* (PTV). En estos métodos se estiman campos de velocidad a partir de muestras reducidas en cada ventana de interrogación, donde la varianza del ruido de medición es desconocida. El estadístico t permite construir intervalos de confianza sobre la velocidad media local y determinar si las fluctuaciones observadas son estadísticamente significativas o atribuibles al ruido instrumental, lo cual es crítico en flujos de baja turbulencia Westerweel [1997], Adrian and Westerweel [2011].

Respecto al Teorema de Cochran, la t de Student no satisface sus condiciones: al no ser Normal, el estadístico $(n-1)S_n^2/\sigma^2$ no sigue exactamente una distribución χ_{n-1}^2 . A diferencia de la Exponencial, cuyas colas moderadas permiten que el Teorema Central del Límite compense esta desviación con $n = 100$, las colas pesadas de la t de Student ralentizan significativamente dicha convergencia, produciendo intervalos de confianza inválidos incluso para tamaños muestrales moderados.

2.3. Generación de Datos Aleatorios

Para comparar las distribuciones χ^2 , exponencial a tasa $\lambda = 0,5$ y t de student, se genero una muestra aleatoria de 100 datos que distribuyen normal con $\mu = 2$ y $\sigma = 2$ con la libreria de python `scipy.stats`. Posteriormente, se realizo el siguiente procedimiento con cada una de las distribuciones mencionadas, utilizando la muestra generada:

(i) se calculo la varianza muestral (S_n^2) (ii) se determino un intervalo al 95 % de confianza para la varianza poblacional (σ^2) (iii) se realizaron 100 iteraciones del proceso anterior para obtener una distribucion de los intervalos de confianza y (iv) se realizaron otras 900 iteraciones para obtener un total de 1000 intervalos de confianza, con el fin de analizar la frecuencia con la que estos intervalos contienen el valor real de σ^2 .

Es importante mencionar que la muestra aleatoria se generó utilizando la semilla 200, con el fin de garantizar la reproducibilidad de los resultados. Además, se asumen los siguientes supuestos: (i) los X_i son independientes e idénticamente distribuidos (i.i.d.); (ii) la varianza poblacional σ^2 es finita, lo que impone la restricción $\nu > 2$ para la t de Student; (iii) el estadístico $(n-1)S_n^2/\sigma^2 \sim \chi_{n-1}^2$ se aplica de forma homogénea a las tres distribuciones, asumiendo que $n = 100$ es suficiente para que el Teorema Central del Límite justifique la aproximación en los casos no normales; y (iv) el IC se construye con dos colas simétricas en probabilidad ($\alpha/2$ en cada cola), utilizando los cuantiles $\chi_{\alpha/2, n-1}^2$ y $\chi_{1-\alpha/2, n-1}^2$.

3. Resultados y Análisis

La Figura 1 muestra los histogramas de las muestras generadas junto a sus densidades teórica y ajustada. En el caso Normal, la muestra presenta un buen ajuste simétrico. La distribución Exponencial exhibe la asimetría positiva característica, con cola derecha extendida. La t de Student muestra una forma simétrica visualmente similar a la Normal, pero con colas más pesadas que, si bien no resultan evidentes en el histograma, tienen consecuencias significativas en la inferencia sobre la varianza.




Figura 1: Histogramas de las muestras generadas con las densidades teórica y ajustada para las distribuciones Normal ($\mu = 5$, $\sigma = 2$), Exponencial ($\lambda = 0,5$) y t de Student ($\nu = 5$). En la fila inferior se muestran los intervalos de confianza del 95 % para la varianza (línea azul), la varianza muestral S_n^2 (cuadrado naranja) y la varianza poblacional real σ^2 (línea vertical roja punteada).

La Figura 2 presenta los 100 intervalos de confianza al 95 % contruidos para cada distribución, ordenados de menor a mayor por su cota inferior. Los intervalos en azul cubren el valor real σ^2 (línea discontinua) y los

rosados no.




Figura 2: Intervalos de confianza al 95 % para σ^2 en 100 repeticiones. Azul: cubre σ^2 real (línea discontinua); rosado: no lo cubre. Cobertura en 100 repeticiones

Distribución Normal. La cobertura fue de 955/1000 (95,5 %), en plena concordancia con el nivel nominal. El Teorema de Cochran se cumple exactamente: bajo normalidad, $(n-1)S_n^2/\sigma^2 \sim \chi_{n-1}^2$ de forma exacta, independientemente de los valores de μ y σ , por lo que el resultado no cambia al variar los parámetros.

Distribución Exponencial ($\lambda = 0,5$). La cobertura fue de 956/1000 (95,6 %), prácticamente idéntica al caso Normal. El Teorema de Cochran no aplica de forma exacta, pero con $n = 100$ el Teorema Central del Límite garantiza la convergencia suficiente de S_n^2 , dado que la Exponencial tiene colas moderadas (curtosis = 6, invariante en λ). Por ello, la cobertura se mantiene estable independientemente del valor de λ .

Distribución t de Student. La cobertura fue de 862/1000 (86,2 %), muy por debajo del 95 % nominal: el intervalo falla casi el triple de las veces esperadas. El Teorema de Cochran no se cumple con $n = 100$. La causa son las colas pesadas de la t de Student, cuya curtosis $\kappa = 6/(\nu - 4)$ diverge para $\nu \rightarrow 4^+$, impidiendo que S_n^2 converja a χ_{99}^2 con rapidez suficiente Lumley et al. [2002]. En la Figura 2 esto se manifiesta como un sesgo sistemático: los intervalos fallidos se concentran en los de menor amplitud, cuya cota superior queda a la izquierda de σ^2 . El resultado sí cambia con ν : a mayor ν las colas se alivian y la cobertura converge al 95 %; con ν cercano a 2 el deterioro sería aún más severo.

4. Conclusión

Los resultados obtenidos permiten concluir que el Teorema de Cochran se cumple de forma exacta únicamente bajo normalidad, donde la cobertura empírica (95,5 %) coincide con el nivel nominal. Para la distribución Exponencial, la cobertura (95,6 %) confirma que la aproximación χ^2 es asintóticamente válida con $n = 100$, gracias a sus colas moderadas. En contraste, la t de Student evidencia que colas pesadas comprometen severamente la validez del intervalo (86,2 %), incluso para muestras de tamaño moderado.

En cuanto a los supuestos, los resultados muestran que el más crítico es la normalidad de los datos: el supuesto de que $n = 100$ justifica la aproximación asintótica resultó válido para la Exponencial, pero insuficiente para la t de Student. Esto implica que, antes de aplicar el estadístico χ^2 , es fundamental verificar que la distribución subyacente no presente colas significativamente más pesadas que la Normal.

Referencias

- R. A. Fisher. On the mathematical foundations of theoretical statistics. *Philosophical Transactions of the Royal Society of London, Series A*, 222:309–368, 1922. doi: 10.1098/rsta.1922.0009.
- W. G. Cochran. The distribution of quadratic forms in a normal system, with applications to the analysis of covariance. *Mathematical Proceedings of the Cambridge Philosophical Society*, 30(2):178–191, 1934. doi: 10.1017/S0305004100016595.
- Student. The probable error of a mean. *Biometrika*, pages 1–25, 1908.
- J. Westerweel. Fundamentals of digital particle image velocimetry. *Measurement Science and Technology*, 8(12):1379–1392, 1997. doi: 10.1088/0957-0233/8/12/002.
- R. J. Adrian and J. Westerweel. *Particle Image Velocimetry*. Cambridge University Press, New York, 2011.
- T. Lumley, P. Diehr, S. Emerson, and L. Chen. The importance of the normality assumption in large public health data sets. *Annual Review of Public Health*, 23:151–169, 2002. doi: 10.1146/annurev.publhealth.23.100901.140546.